

Задание на финальный проект

In

Входная информация

Датасет

- BPI 2019 Challenge ~~порезан на 3 части~~
- ~~Синтетический текстовый датасет (на англ.) – без разметки~~

Либы

- Стандартный DS-набор (scikit-learn, pandas, numpy)
- pm4py (пришлем тестовый ноутбук)

Out

Выходной формат

- Воспроизводимый Jupyter-ноутбук
- ~~Отчет (рассказ, без презентации)~~
- ~~Защита проекта~~

10/10

Критерии оценки

Алгоритмы

Корректность отработки алгоритма
Скорость отработки алгоритма

Презентация

~~Рассказать про подход и сделать общие выводы о процессе~~
Прокомментировать, почему получились такие метрики и такое качество кластеризации

To
do

Задачи

- Прочитать csv-файл
- **Выполнить разбиение процесса на группы / кластера**
- Посчитать качество кластеризации метриками:
 - Fitness (есть в pm4py)
 - ~~Silhouette + DBCV(*)~~
- Отрисовать граф процесса:
 - DFG
- Сконвертировать граф в сеть Петри (Alpha+ (есть в pm4py))
- Посчитать метрики процесса:
 - Среднее время на кластер
 - ~~Найти самый частый цикл~~
 - ~~Feature Importance влияние факторов на время выполнения процесса~~
- ~~Выполнить кластеризацию и суммаризацию текста~~

val

Валидация

- ~~Прогон ноутбука на отдельном процессном датасете~~
- ~~Валидация текстов на отдельном датасете~~
- ~~Сравнение количественных метрик с нашим расчетом~~